DBSCAN Report

2016024893 오성준

1. Summary of your algorithm

□ Data 를 받은 뒤에 Clustering 을 실행합니다. 다음과 같은 단계로 clustering 을 실행합니다.

1) 전체 Data 를 돌면서 Neighbor 들을 찾아서 2 중 list 의 형태로 저장합니다. Neighbor 의 기준은 두 점 사이의 거리가 EPS 보다 작거나 같을 때 입니다.

2) 1 번에서 저장한 Neighbor 를 기준으로 다시 전체를 돌면서 Neighbor 의 수가 Min Points 값보다 같거나 크다면 Core Point 라 생각하고 그 Key 값을 list 에 저장합니다.

3) 마지막으로 저장한 Core point 에 대해서 BFS 를 실행해서 cluster 에 대해서 점들을 모아 둔 뒤에 저장합니다. 그 중에서 개수가 많은 N 개의 cluster 를 output file 에 format 에 맞게 write 합니다.

□ 구현에 대한 세부적인 사항은 2 번에서 설명하겠습니다.

2. Detailed description of your codes (for each function)

□ DBSCAN 이라는 class 를 만들어서 구현했습니다. 그리고 main function 을 만들어서 DBSCAN object 를 만들어서 과제를 수행했습니다. 다음부터 DBSCAN class function 에 대해서 설명하겠습니다.

1) Init function

```
def __init__(self, data, n, eps, minpts, input_f):
        self.input_string = input_f
        self.N = n
        self.Eps = eps
        self.Minpts = minpts

        self.Data = {}
        self.Data_size = data.shape[0]

        # dataframe is tooooooo slow to get neighbor
        # so i use dictionary (hash)
        for i in range(self.Data_size):
            d = data.iloc[i]
```

```
                self.Data[d['key']] = (d['x'], d['y'])

        self.Neighbors = {}
        self.Neighbors = {int(key): [] for key,xy_tuple in self.Data.items()}

        self.get_neighbor()
        # find directly density reachable relationships
        # it's like vector in cpp

        self.Core = [key for key, neighbors in self.Neighbors.items() if len(neighbors) >=
self.Minpts]
        # list comprehension is used to pick up core point

        self.Clusters = []
        self.cluster()

        self.write_clusters()
```

- DBSCAN 과 관련된 정보를 받은 다음 class 에 선언된 함수들을 불러서 전체적인 프로젝트의 진행을 보여줍니다.
- 처음에는 data 를 dataframe 의 형태로 받아서 진행하려 했으나, 코드를 구현하면서 프로그램의 실행 시간이 너무 느려져서 dictionary 를 사용해서 최대한 실행 시간을 줄여보았습니다.
- 그 이후에 각 key 에 대해서 neighbor 를 저장하는 get_neighbor function 을 사용했습니다. 그러고 난 후엔 list comprehension 을 사용해서 core points 의 key 값을 저장한 후에 clustering 을 하고 각 cluster 들을 정해진 file 형식으로 write 하는 과정을 거쳐서 프로그램을 실행합니다.

2) Get distance function

```
def get_distance(self,a,b):
        return ((a[0]-b[0])**2 + (a[1]-b[1])**2)**0.5
```

- 말 그대로 두 점 사이의 거리를 구하는 함수입니다. Neighbor 를 구할 때 사용합니다.

3) Get neighbor function

```
def get_neighbor(self):
        for i in range(self.Data_size):
            point_i = self.Data[i]
            for j in range(i + 1, self.Data_size):
                point_j = self.Data[j]
                distance = self.get_distance(point_i, point_j)
                if distance <= self.Eps:
```

```
                    self.Neighbors[i].append(j)
                    self.Neighbors[j].append(i)
```

- N combinations 2 만큼 두 점의 조합을 보면서 두 점 사이의 거리를 구하고 그 값이 EPS 값보다 같거나 작으면 쌍방의 neighbor 이기 때문에 서로의 neighbor 에 등록했습니다.

4) Cluster function

```
def cluster(self):
        # a = {} print(1 in a) -> return false
        # check_dict = {}
        visit = [False for i in range(self.Data_size)]
        # in insert delete list is O(N) but queue is O(1) so i import queue
        # q.put(self.Core[0])

        for core_point in self.Core:
            if visit[core_point]: continue
            q = Queue()
            q.put(core_point)
            tmp = []
            while True:
                if q.qsize() == 0: break
                now = q.get()

                if now not in self.Core: continue
                # for 문 안에서 계속 확인하는 것보다 이게 나을것이라 생각함

                for point in self.Neighbors[now]:
                    if visit[point]: continue
                    q.put(point)
                    tmp.append(point)
                    visit[point] = True

            self.Clusters.append(tmp)

        self.Clusters.sort(key = len)
        self.Clusters.reverse()
```

- Core point 에 대해서 BFS 를 실행해서 cluster 들을 연결했습니다.
- 여기서 list 를 사용하지 않고 외부 queue 를 사용했는데, 그 이유는 list 를 이용한 pop 과 insert 의 시간복잡도가 O(N)인데 비해서, 외부 queue 는 시간복잡도가 O(1)이라서 시간을 줄여 줄거라 생각했기 때문입니다.

- 두번째로 visit list 를 사용했는데, data 가 많을 때는 문제가 있을 수 있다는 생각이 들었습니다. 우선은 구현했지만 나중에 좋은 방법을 찾아보고 싶었습니다. 아무튼 이 list 는 queue 에 넣거나 cluster 에 등록할 때, 이미 방문했다면, 중복해서 처리하지 않도록 하는 list 로 방문했다면 값이 True 입니다.
- Cluster 들을 class 의 clusters list 에 append 를 해서 코드를 마무리 지었습니다.

5) Write clusters function

```
def write_clusters(self):
        for i in range(self.N):
            file_name = self.input_string + "_cluster_" + str(i) + ".txt"
            f = open(file_name, 'w')
            self.Clusters[i].sort()
            for point in self.Clusters[i]:
                f.write(str(point)+'\n')
            f.close()
```

- File 들을 format 에 맞게 만들어서 저장합니다. Cluster 를 개수만큼 sorting 한 다음에 N 개만큼만 file 을 저장합니다.

3. Instructions for compiling your source codes at TA's computer

1) requirements.txt

이번 과제부터 python 가상 환경에서 진행하여 **requirements.txt** 파일을 첨부해서 함께 git lab에 올립니다. 보고서 3번 내용 자체를 지금에서야 이해하게 된 점에 대해 죄송합니다. 동시에 보고서에 사진도 첨부합니다.

```
cycler==0.10.0
kiwisolver==1.3.1
matplotlib==3.4.2
numpy==1.20.3
pandas==1.2.4
Pillow==8.2.0
pyparsing==2.4.7
python-dateutil==2.8.1
pytz==2021.1
six==1.16.0
```

2) 실행 명령어

파일의 실행은 명세와 똑같이 구현했습니다.

```
(ds) seongjun-o@seongjun-oui-MacBookPro source % python clustering.py input1.txt 8 15 22
86.9407000541687
(ds) seongjun-o@seongjun-oui-MacBookPro source % python clustering.py input2.txt 5 2 7
5.074440002441406
(ds) seongjun-o@seongjun-oui-MacBookPro source % python clustering.py input3.txt 4 5 5
6.98406195640564
```

3) 채점

채점 시스템이 잘 작동하지 않아서 친구에게 부탁해서 채점을 해보았습니다. 잘 채점이 된 모습입니다.

```
PS G:\내 드라이브\데이터사이언스\Project3\data-3\data-3> .\PA3.exe input1
98.90826점
PS G:\내 드라이브\데이터사이언스\Project3\data-3\data-3> .\PA3.exe input2
94.60035점
PS G:\내 드라이브\데이터사이언스\Project3\data-3\data-3> .\PA3.exe input3
99.97736점
PS G:\내 드라이브\데이터사이언스\Project3\data-3\data-3>
```

4. Any other specification of your implementation and testing

□ 이번 과제를 진행하면서 data들을 시각화 하고 싶다는 생각이 들어서 **show.py**에 matplotlib을 이용해서 scatter로 점들을 시각화 했습니다. 동시에 clustering 이후에 색깔을 붙여서 다시 시각화 해서 전 후를 비교할 수 있도록 했습니다. 아래에 결과물을 첨부합니다.

1) Input1.txt

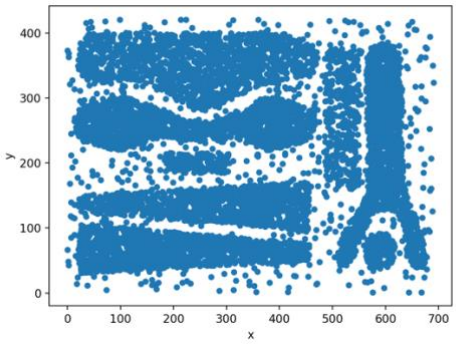

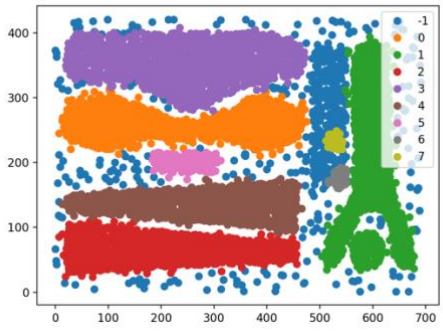

□ 아래로 긴 직사각형 모양의 cluster가 제대로 잡히지 않았는데, 우선 결과값은 대략 99점으로 제대로 나오긴 했습니다.

□ Eps 값을 늘리거나 min points 값을 줄이면 cluster에 포함되곤 했지만, 단독으로 존재하기 보단, 주변의 cluster와 함께 묶이는 상황이 나타나곤 했습니다.

□ Eps 값이 17, min points 값이 22일 때,

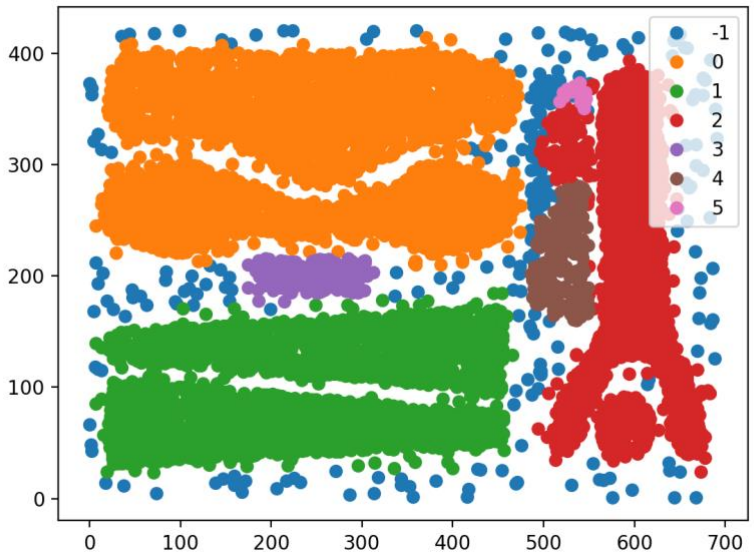

- Cluster의 수가 전체적으로 줄었고, 더 많은 점이 cluster에 포함된 모습이지만 결과가 만족스럽진 못하다고 생각합니다. 그 이유는 구분되어야 할 cluster가 합쳐졌기 때문입니다.

- Eps 값이 15, min points 값이 20일 때,

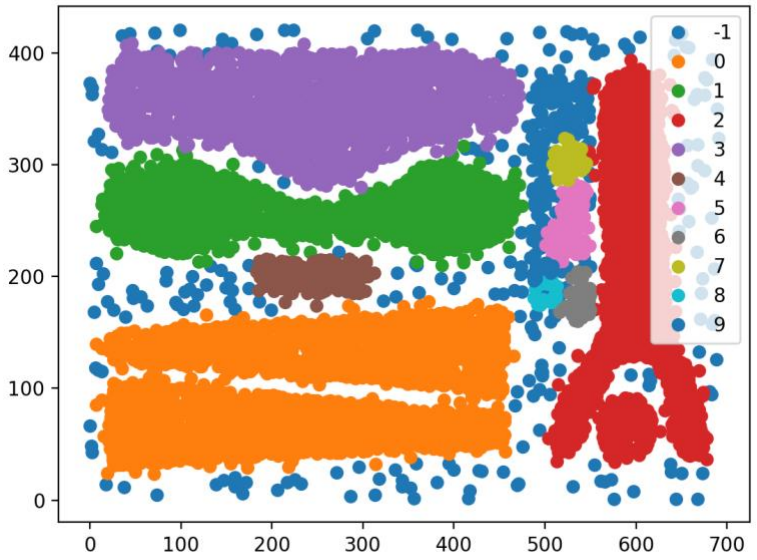

- 확실히, 아래로 긴 직사각형 부분에서 clustering되는 부분이 많아졌지만, 그럼에도 불구하고 각자가 쪼개진 모습입니다. 그리고 이번에는 주황색에 해당하는 부분이 합쳐졌기 때문에 마찬가지로 지금 시점이 이득이라고 볼 수 없을 겁니다.

- 이번 시도를 통해서 DBScan이 확실히 parameter에 민감하다는 것과, 시각적으로

완벽히 cluster라고 할 수 있는 것들이 제대로 clustering 되지 않을 수 있다는 것을 알 수 있었습니다.

2) Input2.txt

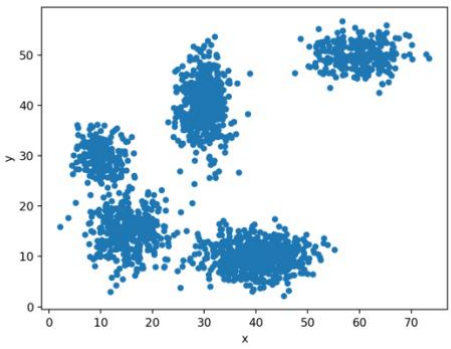

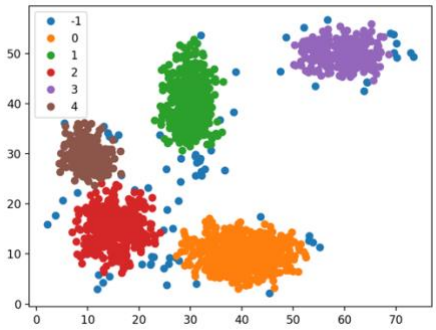

3) Input3.txt

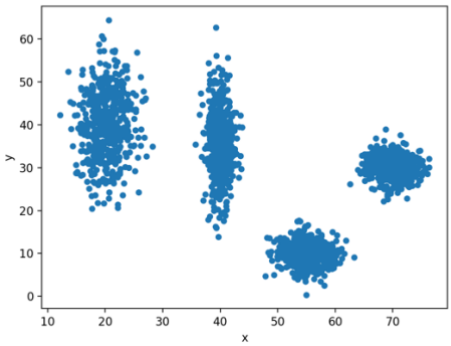

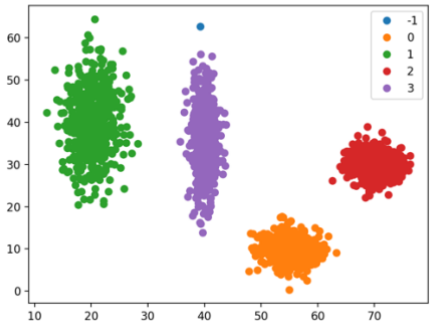

□ Input2와 input3에 관해선 특별한 점이 발견되지 않고 잘 clustering 됐다고 생각해서 다른 실험을 해보진 않았습니다.

□ 전반적인 data의 분포와 결과를 분석할 수 있고, 여러가지 실험을 해볼 수 있어서 좋았습니다. Show.py의 구현 부분은 다음과 같습니다.

□ Cluster를 나누기 전의 코드

```
data = pd.read_csv(input_f, header = None, sep = '\t', names = ['key', 'x, 'y'])
    data.plot.scatter(x = 'x', y = 'y')
    plt.show(block = True)
    dbscan = DBSCAN(data ,int(n), int(eps), int(minpts), input_f[:-4])
```

□ Scatter와 plt를 이용해서 단순한 점들의 분포를 보여주도록 했습니다.

□ Cluster를 나눈 이후의 코드

```
# for c in self.Clusters: print(len(c))
        self.label = [-1 for i in range(self.Data_size)]
```

```
        self.write_clusters()

        self.D['label'] = self.label
        groups = self.D.groupby('label')

        fig, ax = plt.subplots()
        ax.margins(0.05) # Optional, just adds 5% padding to the autoscalig
        for name, group in groups:
            ax.plot(group['x'], group['y'], marker='.', linestyle='', ms=12, label=name)
        ax.legend()

        plt.show()
```

- 각 점에 대해서 label을 받은 뒤에 label에 맞게 색깔을 다르게 해서 보여주도록 했습니다.

5. 이전 과제에 대해서

- 앞서 말한 것처럼 저는 지금에서야 보고서 3 번 문항에 대해서 알게 되었고, 모든 과제를 가상 환경에서 다시 실행했습니다. 그리고 현재의 requirements.txt 환경에서 잘 작동하는 것을 확인했습니다. 이전 과제들도 채점하실 때 참고 하셨으면 좋겠습니다.

- 2 번째 과제에 대해서 말씀드릴 건 제가 구현한 dt.py 코드를 보면서 보고서를 쓰던 도중에 한글로 주석을 달아놓고 그대로 내는 바람에 아마도 dt.py 가 잘 실행이 되지 않았을 수도 있을 것 같습니다.

```
# -*- coding: utf-8 -*-
```

  이 주석을 가장 맨 위에 붙여놓으면 잘 작동하는 것을 확인했습니다. 참고해서 채점해 주셨으면 합니다.

- 여러모로 이런 부분들을 미리 확인하지 못하고 과제를 제출한 뒤에 뒤늦게 말하는 점 죄송합니다. 이번 과제와 recommender 과제는 주의해서 보고서를 잘 작성하도록 하겠습니다.